

Reporte de Analisis Detallado

Carlos Merino

07 de Febrero, 2026

Contents

- Extracción e Importación de Datos	1
- Extracción de la Fuente	2
- Importación a R	2
- Limpieza basica y estandarizacion	2
- Carga de Librerías	2
- Proceso de Estandarización	2
- Exploracion inicial y estadistica descriptiva	3
- glimpse(data_clean)	3
- summary(data_clean)	3
- head(data_clean)	4
- Transformacion de los datos a traves de variables nuevas	4
- Graficos de ggplot2	5
- Histograma	5
- Densidad por categoría de aprobación	5
- Boxplot	5
- Gráfico de dispersión	5
- Gráfico de barras	10
- Análisis del ratio estudio/sueño	10
- Extracción e Importación de Datos	

La metodología de obtención y carga de datos se realizó en los siguientes pasos:

- Extracción de la Fuente

Primero se descargan los datos desde <https://www.kaggle.com/>, escogiendo la base de datos “student_exam_scores.csv”. Luego se guarda escogiendo cualquier directorio de alguna carpeta, en este caso, se escogió la ruta:

```
"C:/Users/carlo/Desktop/Proyectos propios/analisis con reporte de datos/Reporte de Datos/student_exam_s
```

- Importación a R

Después se importa esta base de datos al entorno de R con el siguiente código:

```
data <- read_csv("student_exam_scores.csv")
```

Donde:

Elemento	Tipo	Descripción
<code>data</code>	Objeto	Es el nombre con el que guardaremos esta base de datos.
<code>read_csv()</code>	Función	Función que lee archivos en formato CSV, reconociendo los tipos de datos de las columnas.
<code>(student_exam...)</code>	Directorio	Ubicación del archivo

- Limpieza basica y estandarización

Este análisis se basa en el conjunto de datos de puntajes estudiantiles, el cual se ha limpiado y estandarizado.

- Carga de Librerías

Para la estandarización de nombres de columnas, se utilizó la librería janitor.

- Proceso de Estandarización

Se aplicó la función `clean_names()` para estandarizar los nombres de todas las columnas, y la función `mutate()` para asegurar el formato de la variable clave del estudiante.

El código utilizado fue:

```
data <- data %>%
  janitor::clean_names() %>%
  mutate(student_id = as.character(student_id))
```

Donde:

Elemento	Tipo	Descripción
<code>data</code>	Objeto	Estandariza los nombres de todas las columnas (ej. de 'Previous Scores' a 'previous_scores').
<code>janitor::clean_names()</code>	Limpieza	Función que lee archivos en formato CSV, reconociendo los tipos de datos de las columnas.
<code>mutate()</code>	Transformación	Modifica la columna <code>student_id</code> para asegurar que se almacene como un carácter.

- Exploracion inicial y estadistica descriptiva

Esta etapa se realiza sobre el conjunto de datos transformado (`data_clean`) para obtener un primer vistazo a la estructura, validar el tipo de dato de las nuevas variables y resumir las características centrales de las variables numéricas.

- glimpse(data_clean)

La función `glimpse()` proporciona un resumen conciso de las filas, columnas y, lo más importante, el tipo de dato de cada variable (`dbl`, `chr`). Esto confirma que las transformaciones (como la de `student_id` a carácter) se realizaron correctamente.

```
glimpse(data)
```

```
## Rows: 200
## Columns: 6
## $ student_id      <chr> "S001", "S002", "S003", "S004", "S005", "S006", "S0~
## $ hours_studied   <dbl> 8.0, 1.3, 4.0, 3.5, 9.1, 8.4, 10.8, 2.0, 5.6, 1.3, ~
## $ sleep_hours      <dbl> 8.8, 8.6, 8.2, 4.8, 6.4, 5.1, 6.0, 4.3, 5.9, 8.9, 5~
## $ attendance_percent <dbl> 72.1, 60.7, 73.7, 95.1, 89.8, 58.5, 54.2, 75.8, 81.~
## $ previous_scores    <dbl> 45, 55, 86, 66, 71, 75, 88, 55, 84, 70, 81, 85, 71, ~
## $ exam_score        <dbl> 30.2, 25.0, 35.8, 34.0, 40.3, 35.7, 37.9, 18.3, 34.~
```

- `summary(data_clean)`

La función `summary()` es crucial, ya que calcula métricas descriptivas esenciales (media, mediana, cuartiles) para las variables continuas.

```
summary(data)
```

```

##   student_id      hours_studied    sleep_hours attendance_percent
## Length:200          Min. : 1.000    Min. :4.000     Min. : 50.30
## Class :character   1st Qu.: 3.500   1st Qu.:5.300     1st Qu.: 62.20
## Mode  :character   Median : 6.150   Median :6.700     Median : 75.25
##                      Mean  : 6.325   Mean  :6.622     Mean  : 74.83
##                      3rd Qu.: 9.000   3rd Qu.:8.025     3rd Qu.: 87.42
##                      Max. :12.000   Max. :9.000     Max. :100.00

```

```

## previous_scores    exam_score
## Min.   :40.0      Min.   :17.10
## 1st Qu.:54.0      1st Qu.:29.50
## Median :67.5      Median :34.05
## Mean   :66.8      Mean   :33.95
## 3rd Qu.:80.0      3rd Qu.:38.75
## Max.   :95.0      Max.   :51.30

```

- head(data_clean)

La función head() permite visualizar las primeras filas del dataset. Esto sirve como una validación rápida para asegurar que las nuevas variables categóricas (pass_fail, previos_cat) se han creado con los valores esperados.

```
head(data)
```

```

## # A tibble: 6 x 6
##   student_id hours_studied sleep_hours attendance_percent previous_scores
##   <chr>          <dbl>        <dbl>            <dbl>           <dbl>
## 1 S001             8          8.8            72.1            45
## 2 S002            1.3         8.6            60.7            55
## 3 S003             4          8.2            73.7            86
## 4 S004            3.5         4.8            95.1            66
## 5 S005            9.1         6.4            89.8            71
## 6 S006            8.4         5.1            58.5            75
## # i 1 more variable: exam_score <dbl>

```

- Transformacion de los datos a traves de variables nuevas

A partir del dataset limpio, se crean seis nuevas variables categóricas y de ratio (como el nivel de aprobación, el nivel previo y el balance estudio/sueño) esenciales para el análisis de rendimiento.

```

data_clean <- data %>%
  mutate(
    study_per_sleep = hours_studied / sleep_hours,
    previos_cat = case_when(
      previous_scores >= 80 ~ "Alto",
      previous_scores >= 60 ~ "Medio",
      TRUE ~ "Bajo"
    ),
    exam_level = case_when(
      exam_score >= 40 ~ "Alto",
      exam_score >= 30 ~ "Medio",
      TRUE ~ "Bajo"
    ),
    pass_fail = if_else(exam_score >= 30, "Aprobado", "Reprobado"),
    exam_zscore = (exam_score - mean(exam_score, na.rm = TRUE)) / sd(exam_score, na.rm = TRUE),
    exam_percentile = percent_rank(exam_score) * 100
  )

```

Donde:

Elemento	Tipo	Descripción
<code>student_id</code>	Carácter	Asegura que el ID sea tratado como texto, no como valor numérico.
<code>study_per_sleep</code>	Ratio (Numérico)	Mide el balance entre el tiempo dedicado al estudio y el descanso (clave para el gráfico de burbujas).
<code>previos_cat</code>	Categórica	Clasifica el historial académico en Alto, Medio o Bajo para análisis comparativos.
<code>exam_level</code>	Categórica	Clasifica el puntaje del examen en Alto, Medio o Bajo.
<code>pass_fail</code>	Binaria	Determina el estado de aprobación/reprobación (Aprobado ≥ 30 , Reprobado < 30). Crucial para la correlación.
<code>exam_zscore</code>	Numérico	Estandariza el puntaje para medir qué tan lejos está de la media general.
<code>exam_percentile</code>	Numérico	Mide el porcentaje de estudiantes que obtuvieron un puntaje igual o inferior.

- Graficos de ggplot2

- Histograma

El **histograma** a continuación muestra la distribución de la frecuencia de los puntajes obtenidos, con una línea vertical indicando la **media general** del examen. Esto permite identificar rápidamente la concentración de resultados.

- Densidad por categoría de aprobación

El **gráfico de densidad** compara las distribuciones de puntajes para los estudiantes que **Aprobaron** y **Reprobaron**. La densidad es clave para visualizar la separación entre ambos grupos respecto al umbral de aprobación.

- Boxplot

Este **gráfico de cajas y bigotes (Boxplot)** evalúa la distribución del puntaje del examen actual segmentado por la **categoría de puntaje previo** (Bajo, Medio, Alto). La caja muestra la mediana y los cuartiles de cada grupo.

- Gráfico de dispersión

El **gráfico de dispersión** a continuación muestra la fuerte **correlación positiva** entre la cantidad de horas dedicadas al estudio y el puntaje obtenido en el examen, diferenciando la tendencia por el resultado final (Aprobado/Reprobado).

. Distribución de puntajes del examen

. Incluye línea de referencia de la media general

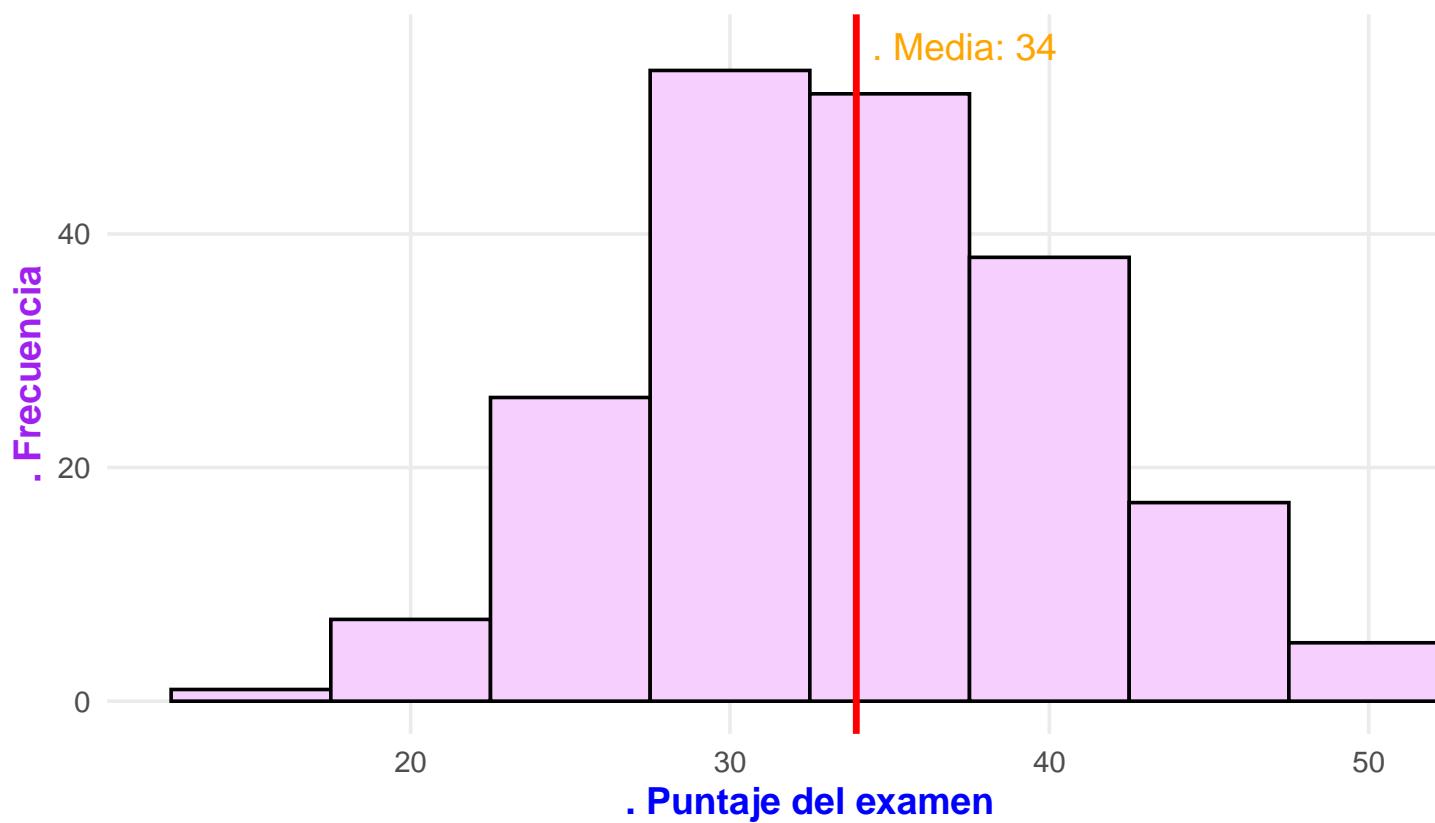


Figure 1: Gráfico de Histograma: Relación entre Frecuencias y Puntaje

. Distribución de densidad por estado de aprobación . Aprobados vs Reprobados

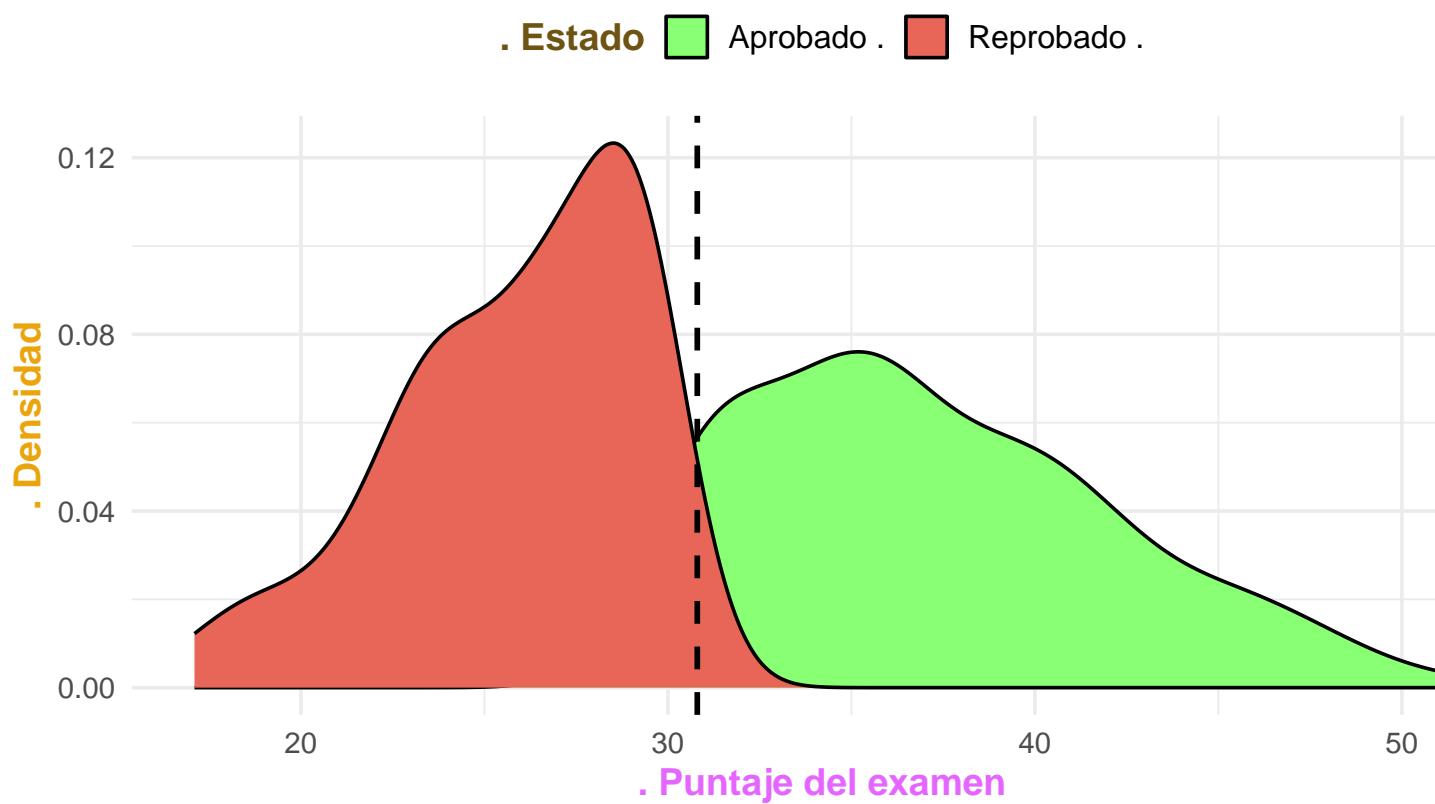


Figure 2: Gráfico de Densidad: Relación entre estado de aprobación

. Distribución de puntajes por nivel académico previo
. Análisis de rendimiento según historial académico

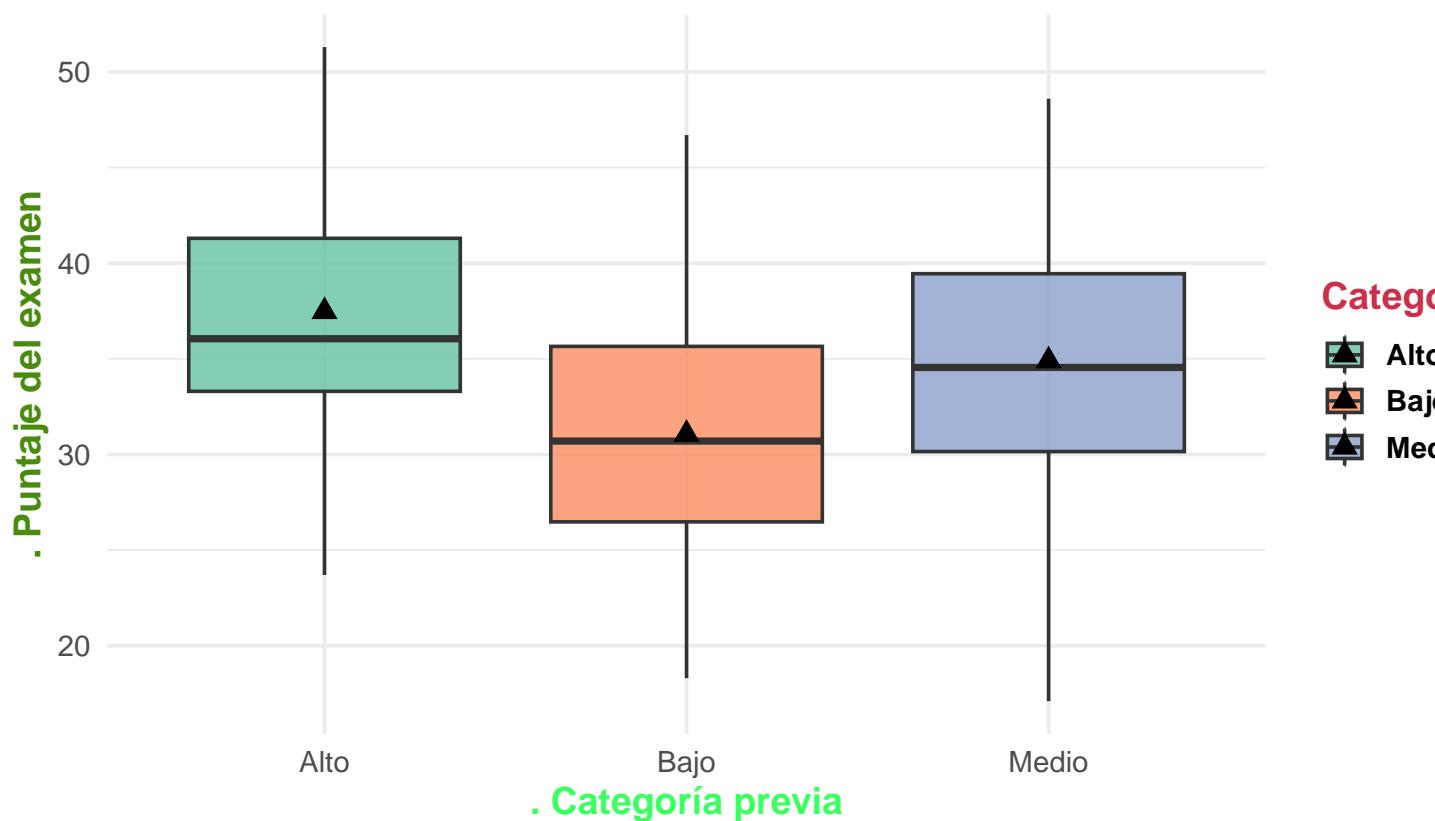


Figure 3: Gráfico de Boxplot: Distribución de puntajes

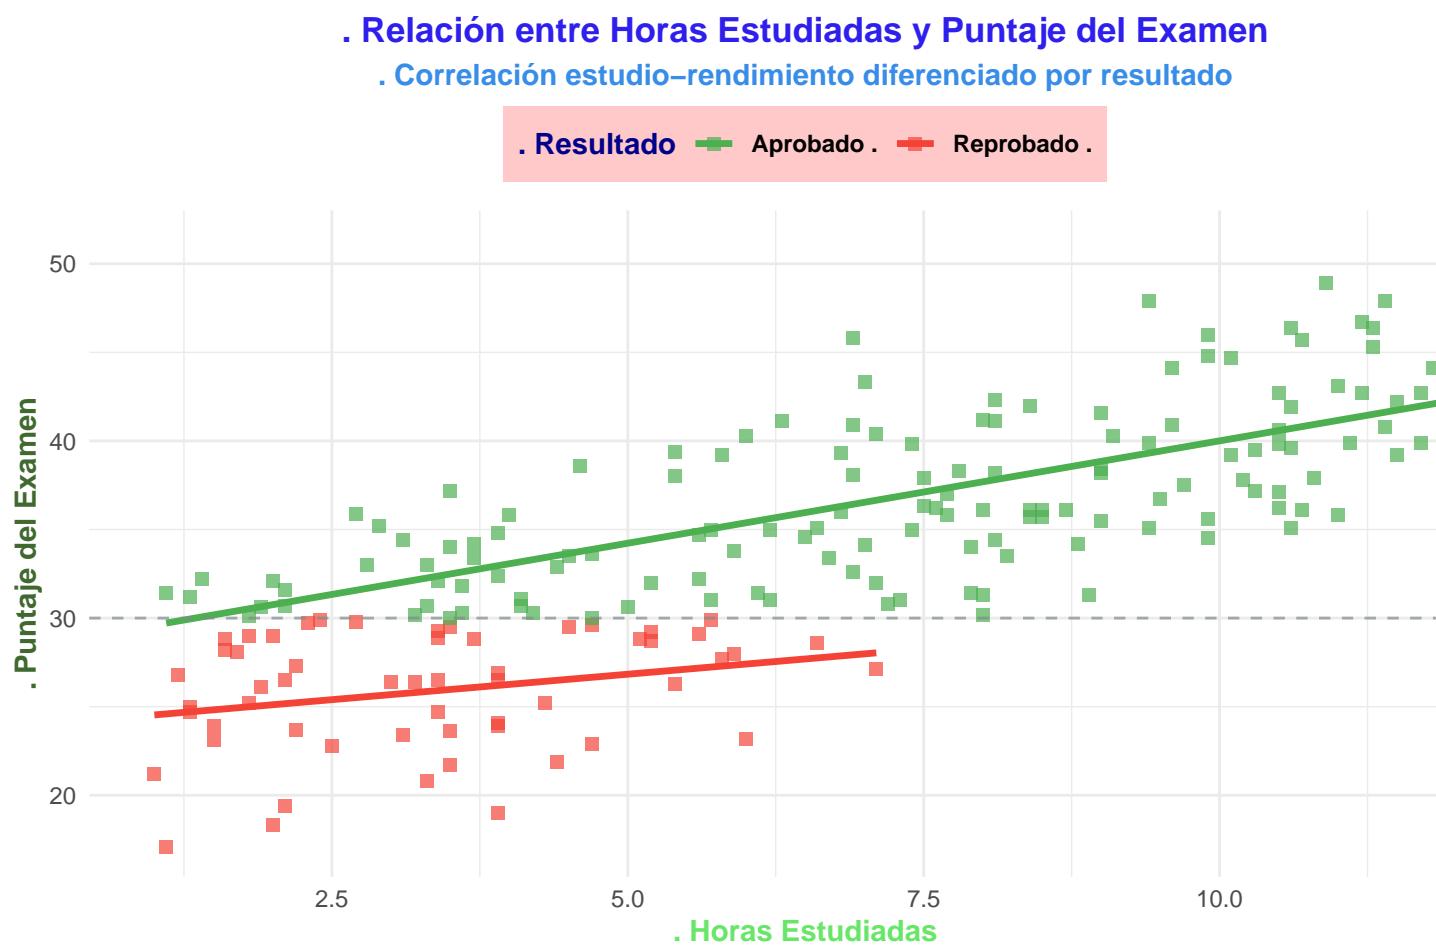


Figure 4: Gráfico de Dispersion: Relación entre horas estudiadas y puntaje del examen

- Gráfico de barras

El gráfico de barras muestra la **frecuencia absoluta y relativa** de estudiantes clasificados en los niveles de desempeño (Bajo, Medio, Alto) creados a partir del puntaje final del examen.

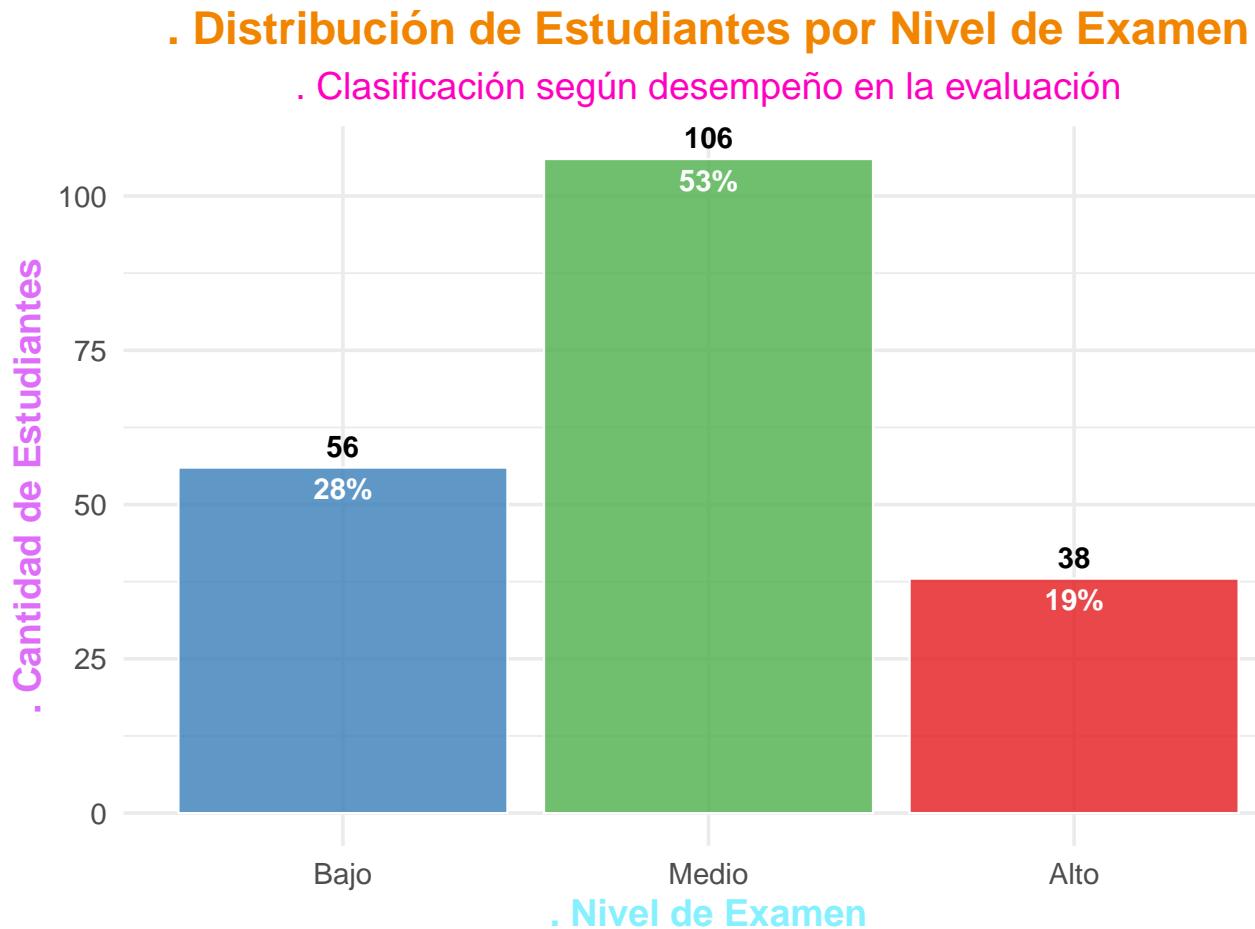


Figure 5: Gráfico de Barras: Distribución de Estudiantes por Nivel de Examen

- Análisis del ratio estudio/sueño

El **gráfico de burbujas** evalúa el **balance entre horas estudiadas y horas de sueño (Ratio)** en relación con el puntaje. El **tamaño de las burbujas** representa las horas de sueño, indicando si el descanso es un factor clave en el rendimiento final.

.. Impacto del Balance Estudio–Sueño en el Rendimiento

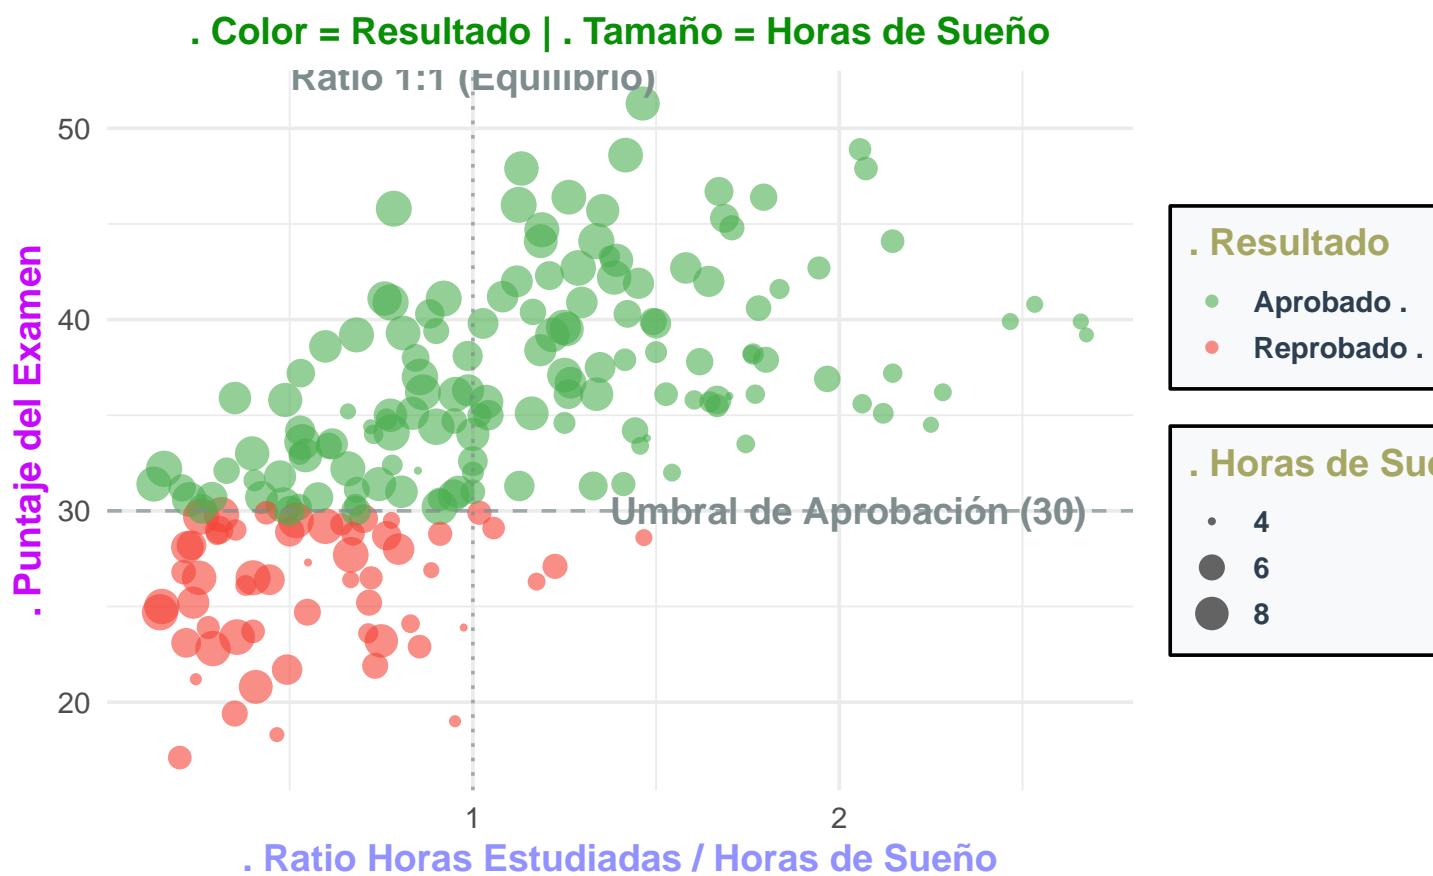


Figure 6: Gráfico de Análisis: ratio estudio/sueño